

leftnoteasy

关注于 机器学习、数据挖掘、并行计算、数学

机器学习中的数学(4)-线性判别分析 (LDA) , 主成分分析(PCA)

版权声明：

本文由LeftNotEasy发布于<http://leftnoteasy.cnblogs.com>, 本文可以被全部的转载或者部分使用, 但请注明出处, 如果有问题, 请联系wheeleast@gmail.com

前言：

第二篇的文章中谈到, 和部门老大一宁出去outing的时候, 他给了我相当多的机器学习的建议, 里面涉及到很多的算法的意义、学习方法等等。一宁上次给我提到, 如果学习分类算法, 最好从线性的入手, 线性分类器最简单的就是LDA, 它可以看做是简化版的SVM, 如果想理解SVM这种分类器, 那理解LDA就是很有必要的了。

谈到LDA, 就不得不谈谈PCA, PCA是一个和LDA非常相关的算法, 从推导、求解、到算法最终的结果, 都有着相当的相似。

本次的内容主要是以推导数学公式为主, 都是从算法的物理意义出发, 然后一步一步最终推导到最终的式子, LDA和PCA最终的表现都是解一个矩阵特征值的问题, 但是理解了如何推导, 才能更深刻的理解其中的含义。本次内容要求读者有一些基本的线性代数基础, 比如说特征值、特征向量的概念, 空间投影, 点乘等的一些基本知识等。除此之外的其他公式、我都尽量讲得更简单清楚。

LDA：


LDA的全称是Linear Discriminant Analysis (线性判别分析), 是一种**supervised learning**。有些资料上也称为是Fisher's Linear Discriminant, 因为它被Ronald Fisher发明自1936年, Discriminant这个词我个人的理解是, 一个模型, 不需要去通过概率的方法来训练、预测数据, 比如说各种贝叶斯方法, 就需要获取数据的先验、后验概率等等。LDA是在**目前机器学习、数据挖掘领域经典且热门**的一个算法, 据我所知, 百度的商务搜索部里面就用了不少这方面的算法。

LDA的原理是, 将带上标签的数据(点), 通过投影的方法, 投影到维度更低的空间中, 使得投影后的点, 会形成按类别区分, 一簇一簇的情况, 相同类别的点, 将会在投影后的空间中更接近。要说明白LDA, 首先得弄明白线性分类器(Linear Classifier): 因为LDA是一种线性分类器。对于K-分类的一个分类问题, 会有K个线性函数:

$$y_k(x) = w_k^T x + w_{k0}$$

当满足条件: 对于所有的j, 都有 $y_k > y_j$ 的时候, 我们就说x属于类别k。对于每一个分类, 都有一个公式去算一个分值, 在所有的公式得到的分值中, 找一个最大的, 就是所属的分类了。

上式实际上就是一种投影, 是将一个高维的点投影到一条高维的直线上, LDA最求的目标是, 给出一个标注了类别的数据集, 投影到了一条直线之后, 能够使得点尽量按类别区分开, 当k=2即二分类问题的时候, 如下图所示:



导航

[博客园](#)

[首页](#)

[联系](#)

[订阅](#) XML

[管理](#)

我的标签

[机器学习](#)(7)

[搜索引擎](#)(7)

[Lucene](#)(6)

[machine learning](#)(4)

[pymining](#)(3)

[mathematics](#)(3)

[人工智能](#)(3)

[数据挖掘](#)(3)

[PCA](#)(2)

[Model Combining](#)(2)

[更多](#)

随笔分类

[Hadoop](#)(2)

[Lucene C++重写心得](#)(2)

[Lucene JAVA心得](#)(9)

[安排, 计划, 总结](#)(2)

[分布式存储](#)(2)

[机器学习](#)(7)

[结构设计](#)(1)

[数学](#)(7)

随笔档案

[2012年2月](#) (1)

[2011年9月](#) (1)

[2011年8月](#) (1)

[2011年5月](#) (5)

[2011年3月](#) (1)

[2011年2月](#) (1)

[2011年1月](#) (3)

[2010年12月](#) (2)

[2010年11月](#) (1)

[2010年10月](#) (1)

[2010年9月](#) (2)

[2010年8月](#) (1)

[2010年1月](#) (12)

[2009年12月](#) (2)

[2009年11月](#) (4)

最新评论

1. Re: 机器学习中的数学(5)-强大的矩阵奇异值分解(SVD)及其应用

@echo_TJ当然不是。PCA需要协方差矩阵, 协方差矩阵就是方阵。...

--Stomach_ache

2. Re: 机器学习中的算法(2)-支持向量机(SVM)基础

厉害, 厉害, 膜拜学习!!!

--miffymoon

3. Re: 机器学习中的算法(2)-支持向量

红色的方形的点为0类的原始点、蓝色的方形点为1类的原始点，经过原点的那条线就是投影的直线，从图上可以清楚的看到，红色的点和蓝色的点被原点明显的分开了，这个数据只是随便画的，如果在高维的情况下，看起来会更好一点。下面我来推导一下二分类LDA问题的公式：

假设用来区分二分类的直线（投影函数）为：

$$y = w^T x$$

LDA分类的一个目标是使得不同类别之间的距离越远越好，同一类别之中的距离越近越好，所以我们需要定义几个关键的值。

类别i的原始中心点为：（ D_i 表示属于类别i的点）

$$m_i = \frac{1}{n_i} \sum_{x \in D_i} x$$

类别i投影后的中心点为：

$$\tilde{m}_i = w^T m_i$$

衡量类别i投影后，类别点之间的分散程度（方差）为：

$$\tilde{s}_i = \sum_{y \in Y_i} (y - \tilde{m}_i)^2$$

最终我们可以得到一个下面的公式，表示LDA投影到w后的损失函数：

$$J(w) = \frac{|\tilde{m}_1 - \tilde{m}_2|^2}{\tilde{s}_1 + \tilde{s}_2}$$

我们分类的目标是，使得类别内的点距离越近越好（集中），类别间的点越远越好。分母表示每一个类别内的方差之和，方差越大表示一个类别内的点越分散，分子为两个类别各自的中心点的距离的平方，我们最大化J(w)就可以求出最优的w了。想要求出最优的w，可以使用拉格朗日乘子法，但是现在我们得到的J(w)里面，w是不能被单独提出来的，我们就得想办法将w单独提出来。

我们定义一个投影前的各类别分散程度的矩阵，这个矩阵看起来有一点麻烦，其实意思是，如果某一个分类的输入点集 D_i 里面的点距离这个分类的中心点 m_i 越近，则 S_i 里面元素的值就越小，如果分类的点都紧紧地围绕着 m_i ，则 S_i 里面的元素值越更接近0。

$$S_i = \sum_{x \in D_i} (x - m_i)(x - m_i)^T$$

带入 S_i ，将J(w)分母化为：

$$\begin{aligned} \tilde{s}_i &= \sum_{x \in D_i} (w^T x - w^T m_i)^2 = \sum_{x \in D_i} w^T (x - m_i)(x - m_i)^T w = w^T S_i w \\ \tilde{s}_1^2 + \tilde{s}_2^2 &= w^T (S_1 + S_2) w = w^T S_w w \end{aligned}$$

同样的将J(w)分子化为：

$$|\tilde{m}_1 - \tilde{m}_2|^2 = w^T (m_1 - m_2)(m_1 - m_2)^T w = w^T S_B w$$

这样损失函数可以化成下面的形式：

$$J(w) = \frac{w^T S_B w}{w^T S_w w}$$

这样就可以用最喜欢的拉格朗日乘子法了，但是还有一个问题，如果分子、分母是都可以取任意值的，那就使得有无穷解，我们将分母限制为长度为1（这是用拉格朗日乘子法一个很重要的技巧，在下面将说的PCA里面也会用到，如果忘记了，请复习一下高数），并作为拉格朗日乘子法的限制条件，带入得到：

$$\begin{aligned} c(w) &= w^T S_B w - \lambda(w^T S_w w - 1) \\ \Rightarrow \frac{dc}{dw} &= 2S_B w - 2\lambda S_w w = 0 \end{aligned}$$

机(SVM)基础

x为二维向量，对应的分离超平面是 $w_1 * x_1 + w_2 * x_2 + b = 0$ ，是一条直线。如果你预测的值(x_{11}, x_{12})带入超平面方程后， $w_1 * x_{11} + w_2 * x_{12} + b > 0$ ，则预测的值是+1类；如果 $w_1 * x_{11} + \dots$

--yeepom

4. Re:机器学习中的数学(5)-强大的矩阵奇异值分解(SVD)及其应用

博主，PCA中利用特征值进行降维时对象只局限于方阵？？？

--echo_TJ

5. Re:机器学习中的数学(1)-回归(regression)、梯度下降(gradient descent)

谢谢楼主的分享，之前看过stanford的视频，讲解的很清楚。求一份prml的书，邮箱mtxing69@163.com，感谢。

--mtx

阅读排行榜

1. 机器学习中的数学(5)-强大的矩阵奇异值分解(SVD)及其应用(135796)
2. 机器学习中的算法(2)-支持向量机(SVM)基础(98838)
3. 机器学习中的算法(1)-决策树模型组合之随机森林与GBDT(87145)
4. 机器学习中的数学(4)-线性判别分析(LDA)，主成分分析(PCA)(86194)
5. 机器学习中的数学(1)-回归(regression)、梯度下降(gradient descent)(77766)

评论排行榜

1. 机器学习中的数学(5)-强大的矩阵奇异值分解(SVD)及其应用(60)
2. 机器学习中的算法(2)-支持向量机(SVM)基础(37)
3. 机器学习中的数学(1)-回归(regression)、梯度下降(gradient descent)(34)
4. 机器学习中的数学(4)-线性判别分析(LDA)，主成分分析(PCA)(27)
5. 机器学习中的数学(2)-线性回归，偏差、方差权衡(23)

推荐排行榜

1. 机器学习中的数学(5)-强大的矩阵奇异值分解(SVD)及其应用(65)
2. 机器学习中的算法(2)-支持向量机(SVM)基础(35)
3. 机器学习中的数学(1)-回归(regression)、梯度下降(gradient descent)(27)
4. 机器学习中的算法(1)-决策树模型组合之随机森林与GBDT(26)
5. 为什么Hadoop将一定会是分布式计算的未来？(23)

$$aw \Rightarrow S_B w = \lambda S_W w$$

这样的式子就是一个求特征值的问题了。

对于N(N>2)分类的问题，我就直接写出下面的结论了：

$$S_W = \sum_{i=1}^c S_i$$


$$S_B = \sum_{i=1}^c n_i (m_i - m)(m_i - m)^T$$

$$S_B w_i = \lambda S_W w_i$$

这同样是一个求特征值的问题，我们求出的第i大的特征向量，就是对应的Wi了。

这里想多谈谈特征值，特征值在纯数学、量子力学、固体力学、计算机等等领域都有广泛的应用，特征值表示的是矩阵的性质，当我们取到矩阵的前N个最大的特征值的时候，我们可以说提取到的矩阵主要的成分（这个和之后的PCA相关，但是不是完全一样的概念）。在机器学习领域，不少的地方都要用到特征值的计算，比如说图像识别、pagerank、LDA、还有之后将会提到的PCA等等。

下图是图像识别中广泛用到的特征脸（eigen face），提取出特征脸有两个目的，首先是为了压缩数据，对于一张图片，只需要保存其最重要的部分就是了，然后是为了使得程序更容易处理，在提取主要特征的时候，很多的噪声都被过滤掉了。跟下面将谈到的PCA的作用非常相关。



特征值的求法有很多，求一个D * D的矩阵的时间复杂度是O(D^3)，也有一些求Top M的方法，比如说[power method](#)，它的时间复杂度是O(D^2 * M)，总体来说，求特征值是一个很费时间的操作，如果是单机环境下，是很局限的。

PCA：

主成分分析（PCA）与LDA有着非常近似的意思，LDA的输入数据是带标签的，而PCA的输入数据是不带标签的，所以PCA是一种unsupervised learning。LDA通常来说是一个独立的算法存在，给定了训练数据后，将会得到一系列的判别函数（discriminate function），之后对于新的输入，就可以进行预测了。而PCA更像是一个预处理的方法，它可以将原本的数据降低维度，而使得降低了维度的数据之间的方差最大（也可以说投影误差最小，具体在之后的推导里面会谈到）。

方差这个东西是个很有趣的，有些时候我们会考虑减少方差（比如说训练模型的时候，我们会考虑到方差-偏差的均衡），有的时候我们会尽量的增大方差。方差就像是一种信仰（强哥的话），不一定会有很严密的证明，从实践来说，通过尽量增大投影方差的PCA算法，确实可以提高我们的算法质量。

说了这么多，推推公式可以帮助我们理解。我下面将用两种思路来推导出一个同样的表达式。首先是最大化投影后的方差，其次是最小化投影后的损失（投影产生的损失最小）。

最大化方差法：

假设我们还是将一个空间中的点投影到一个向量中去。首先，给出原空间的中心点：

$$\bar{x} = \frac{1}{N} \sum_{n=1}^N x_n$$

假设u1为投影向量，投影之后的方差为：

$$\frac{1}{N} \sum_{n=1}^N \{u_1^T x_n - u_1^T \bar{x}\}^2 = u_1^T S u_1$$

上面这个式子如果看懂了之前推导LDA的过程，应该比较容易理解，如果线性代数里面的内容忘记了，可以再温习一下，优化上式等号右边的内容，还是用拉格朗日乘子法：

$$u_1^T S u_1 + \lambda_1 (1 - u_1^T u_1)$$

将上式求导，使之等于0，得到：

$$S u_1 = \lambda_1 u_1$$

这是一个标准的特征值表达式了， λ 对应的特征值， u 对应的特征向量。上式的左边取得最大值的条件就是 λ_1 最大，也就是取得最大的特征值的时候。假设我们是要将一个D维的数据空间投影到M维的数据空间中（ $M < D$ ），那我们取前M个特征向量构成的投影矩阵就是能够使得方差最大的矩阵了。

最小化损失法：

假设输入数据 x 是在D维空间中的点，那么，我们可以用D个正交的D维向量去完全的表示这个空间（这个空间中所有的向量都可以用这D个向量的线性组合得到）。在D维空间中，有无穷多种可能找这D个正交的D维向量，哪个组合是最合适的呢？

假设我们已经找到了这D个向量，可以得到：

$$x_n = \sum_{i=1}^D \alpha_{ni} u_i$$

我们可以用近似法来表示投影后的点：

$$\tilde{x}_n = \sum_{i=1}^M z_{ni} u_i + \sum_{i=M+1}^D b_i u_i$$

上式表示，得到的新的 x 是由前M个基的线性组合加上后D - M个基的线性组合，注意这里的 z 是对于每个 x 都不同的，而 b 对于每个 x 是相同的，这样我们就可以用M个数来表示空间中的一个点，也就是使得数据降维了。但是这样降维后的数据，必然会产生一些扭曲，我们用J描述这种扭曲，我们的目标是，使得J最小：

$$J = \frac{1}{N} \sum_{n=1}^N \|x_n - \tilde{x}_n\|^2$$

上式的意思很直观，就是对于每一个点，将降维后的点与原始的点之间的距离的平方和加起来，求平均值，我们就要使得这个平均值最小。我们令：

$$\frac{\partial J}{\partial z_{nj}} = 0 \Rightarrow z_{nj} = x_n^T u_j, \quad \frac{\partial J}{\partial b_j} = 0 \Rightarrow b_j = \bar{x}^T u_j$$

将上面得到的 z 与 b 带入降维的表达式：

$$x_n - \tilde{x}_n = \sum_{i=M+1}^D \{(x_n - \bar{x})^T u_i\} u_i$$

将上式带入J的表达式得到：

$$J = \frac{1}{N} \sum_{n=1}^N \sum_{i=M+1}^D (x_n^T u_i - \bar{x}^T u_i)^2 = \sum_{i=M+1}^D u_i^T S u_i$$

再用上拉普拉斯乘子法（此处略），可以得到，取得我们想要的投影基的表达式为：

$$S u_i = \lambda_i u_i$$

这里又是一个特征值的表达式，我们想要的前M个向量其实就是这里最大的M个特征值所对应的特征向量。证明这个还可以看看，我们J可以化为：

$$J = \sum_{i=M+1}^D \lambda_i$$

也就是当误差J是由最小的D - M个特征值组成的时候，J取得最小值。跟上面的意思相同。

下图是PCA的投影的一个表示，黑色的点是原始的点，带箭头的虚线是投影的向量， Pc_1 表示特征值最大的特征向量， pc_2 表示特征值次大的特征向量，两者是彼此正交的，因为这原本是一个2维的空间，所以最多有两个投影的向量，如果空间维度更高，则投影的向量会更多。

总结：

本次主要讲了两种方法，PCA与LDA，两者的思想和计算方法非常类似，但是一个是作为独立的算法存在，另一个更多的用于数据的预处理的工作。另外对于PCA和LDA还有核方法，本次的篇幅比较大了，先不说了，以后有时间再谈：

参考资料：

prml bishop, introduce to LDA (对不起，这个真没有查到出处)

分类: [机器学习](#), [数学](#)

标签: [machine learning](#), [机器学习](#), [线性分类](#), [主成分分析](#), [LDA](#), [PCA](#)

好文要顶

关注我

收藏该文



LeftNotEasy

关注 - 16

粉丝 - 867

[+加关注](#)

22

0

(请您对文章做出评价)

« 上一篇: [机器学习中的数学\(3\)-模型组合\(Model Combining\)之Boosting与Gradient Boosting](#)

» 下一篇: [机器学习中的数学\(5\)-强大的矩阵奇异值分解\(SVD\)及其应用](#)

posted on 2011-01-08 14:56 [LeftNotEasy](#) 阅读(86194) 评论(27) [编辑](#) [收藏](#)

评论

#1楼[楼主] 2011-01-08 23:14 [LeftNotEasy](#)

@ 丕子

好的：)

[支持\(0\)](#) [反对\(0\)](#)

#2楼 2011-01-10 11:16 [Draco9](#)

支持一下~

P.S. 有一个小错误。

"分母表示每一个类别内的方差之和，方差越大表示一个类别内的点越分散，分子为两个类别各自的中心点的距离的平方，我们最小化 $J(w)$ 就可以求出最优的 w 了。"

应该是最大化 $J(w)$ 。

[支持\(0\)](#) [反对\(0\)](#)

#3楼[楼主] 2011-01-10 12:59 [LeftNotEasy](#)

@ Draco9

这里确实写错了，马上改正过来。谢谢关注：)

[支持\(0\)](#) [反对\(0\)](#)

#4楼 2011-01-13 14:37 [Leo Zhang](#)

LDA让我想到了projection pursuit method 当时用GA去求最佳投影方向 结果被导师批了

[支持\(0\)](#) [反对\(0\)](#)

#5楼[楼主] 2011-01-13 16:55 [LeftNotEasy](#)

@ Leo Zhang

GA是什么？愿求其详~

[支持\(0\)](#) [反对\(0\)](#)

#6楼 2011-01-13 22:08 [Leo Zhang](#)

@ LeftNotEasy

就是遗传算法了 不过设计的不好会导致收敛很慢

[支持\(0\)](#) [反对\(0\)](#)

#7楼[楼主] 2011-01-13 22:19 [LeftNotEasy](#)

@ Leo Zhang

求投影方向为什么要用GA去求呢，LDA这种多项式复杂度的不是更适合吗

[支持\(0\)](#) [反对\(1\)](#)

#8楼 2011-01-14 12:34 Leo Zhang

@ LeftNotEasy

对滴 所以呢当时就被批了

支持(0) 反对(0)

#9楼 2011-01-14 17:52 夏日疯狂

用拉格朗日法是可以求极值的，但是你怎么确定是极大值还是极小值？没有见说明？是求出以后再比较得到最大值？

支持(0) 反对(0)

#10楼[楼主] 2011-01-15 17:41 LeftNotEasy

@ 夏日疯狂

应该这样看，对于分子和分母都一定是恒为正的，而且拉格朗日乘子式求导有下面的式子： $S_b * w = \lambda * S_w * w$ ，将其带入 $J(w)$ 得到，当 w 满足等式的时候， $J(w) = \lambda$ ，而当 w 为第一个eigen vector的时候， λ 取得第一个也是最大的eigen value，对第二、第三个eigen value以此类推

支持(0) 反对(0)

#11楼 2011-02-12 10:48 行隐

收益匪浅，之前看到1楼的转载，发现3楼发现的问题，回来得到验证，感谢博主的分享

支持(0) 反对(0)

#12楼 2011-02-12 19:36 emy_yu

总结的很详细，之前学SVM一直很模糊，谢谢~~

支持(0) 反对(0)

#13楼[楼主] 2011-02-24 17:46 LeftNotEasy

@ 行隐

谢谢关注：)

支持(0) 反对(0)

#14楼 2011-04-10 22:53 JerryLead

顶，好文，学习了。

p.s.有个地方没看明白：

“衡量类别i投影后，类别点之间的分散程度（方差）为：”和

“带入 S_i ，将 $J(w)$ 分母化为：”下面的 S_i 的公式的 S_i 是不是应该是 S_i 的平方啊

支持(0) 反对(0)

#15楼[楼主] 2011-04-12 11:03 LeftNotEasy

@ JerryLead

我回头看了一下，应该是你说的这样，文章中的有一点问题，不过是图片，改起来有一小麻烦，呵呵，我之后有时间再改改，谢谢关注：)

支持(0) 反对(1)

#16楼 2012-03-06 12:43 会飞的瓶子

谢谢您的分享，对我很有帮助！

支持(0) 反对(0)

#17楼 2012-06-20 22:47 幻想时代5

$$y_k(x) = w_k^T x + w_{k0}$$

楼主，我弱弱问下这个 w_k 是怎么个形式？用来干什么的？

支持(0) 反对(0)

#18楼 2012-07-31 15:26 ello

引用

最终我们可以得到一个下面的公式，表示LDA投影到 w 后的损失函数：

支持(0) 反对(0)

#19楼 2012-07-31 15:28 ello

损失函数不是应该越小越好么？为什么“最大化 $J(w)$ 就可以求出最优的 w 了”是不是应该把这个损失函数的分子分母倒过来？

支持(0) 反对(0)

#20楼 2012-11-07 10:11 silence1214

在线性分类器中，说道对于所有的 j 吗如果

$Y_K > y_j$ 那么这些模式就属于类 K ，这个地方我觉得如果 LZ 写成 $y_k(x) > y_j(x)$ 就好多了，这个地方最少让我一下子没明白过来，还是复习了线性判别函数才回头来看明白

支持(0) 反对(0)

#21楼 2012-11-07 14:41 silence1214

@ ello这个损失函数叫法有错误，应该叫做目标函数

支持(0) 反对(0)

#22楼 2013-10-20 09:30 thinkercui

楼主有问题的地方尽量改正吧。当大家发现比较明显的问题时，就不敢相信文章的权威性了。。。

[支持\(0\)](#) [反对\(0\)](#)

#23楼 2014-04-04 10:58 郭志通

感觉不是很直观，投影后的损失最小，损失的是什麼？怎么样才算损失最小？

[支持\(0\)](#) [反对\(0\)](#)

#24楼 2014-12-27 10:40 zhaoyang10

你的公式里，方差的右上角应该都加上²的符号。有几个地方写错了，下面的公式推导不出来。

[支持\(0\)](#) [反对\(0\)](#)

#25楼 2015-03-28 11:20 迁客在行动

二分类问题中的最后一个结论

为什么说这个是求特征值的问题？ S_B 和 S_W 都是方阵， W 是一个列向量。而且又不能保证 S_W 是可逆矩阵，应该说在源数据特征维数超过2时， S_W 的绝对不是特征矩阵， $S_W = S_1 + S_2$ ， S_1 和 S_2 都是由一个列向量乘以行向量得到的，所以秩不可能超过1，而 S_W 就不可能超过2，因为矩阵的秩小于等于两个矩阵的秩的和。

[支持\(0\)](#) [反对\(1\)](#)

#26楼 2015-04-08 17:05 羊羊1995

对于才入门的我，看到这样比较通俗易懂的文章，很是开心，楼主棒棒哒

[支持\(0\)](#) [反对\(0\)](#)

#27楼 2015-10-20 22:22 IAmHere

@ 迁客在行动

S_1 S_2 是由多组列向量乘以行向量得到的矩阵求和

[支持\(0\)](#) [反对\(0\)](#)

[刷新评论](#) [刷新页面](#) [返回顶部](#)

注册用户登录后才能发表评论，请 [登录](#) 或 [注册](#)，[访问网站首页](#)。

【推荐】50万行VC++源码: 大型组态工控、电力仿真CAD与GIS源码库

【推荐】融云即时通讯云 - 豆果美食、Faceu等亿级APP都在用

【推荐】Excel 报表开发18 招式，人人都能做报表

【推荐】阿里云万网域名：.xin .com将推出重磅优惠

【活动】高性能+大数据的HTML5 App开发交流会（深圳站）

最新IT新闻：

- Windows 10强制升级致用户损失300万元大单 专家建议提起诉讼
 - 美国首次发现能“对抗”抗生素“最后一道防线”的细菌
 - 上海环球港开业：华东首家采用新设计的店
 - 美国宇航局发现火星存在冰河时代
 - 芬兰政府指责微软对诺基亚始乱终弃 承诺一个都没兑现
- » [更多新闻...](#)



最新知识库文章：

- 程序员的黄金时代
 - 快速学习者的高效学习策略
 - 一个前端的自我修养
 - 架构漫谈（九）：理清技术、业务和架构的关系
 - 架构漫谈（八）：从架构的角度看如何写好代码
- » [更多知识库文章...](#)